

DNA do Mercado: PCA e Clusterização Aplicados a Ações Americanas

Implementação, fundamentação matemática e interpretação econômica do pipeline de Análise de Componentes Principais (PCA) e agrupamento por K-Means construído em `app.py` para explorar a estrutura de correlação de 40 ações americanas de grande capitalização.

Autor: Pedro Zborowski

Disciplina: Computação Científica e Análise de Dados (CoCADA) — UFRJ

Ferramentas: Python, Streamlit, yfinance, scikit-learn, Plotly

Data: Julho de 2026

1 Introdução e pergunta de pesquisa

O aplicativo "DNA do Mercado" baixa um ano de preços diários de 40 ações americanas de grande capitalização, divididas a priori em 8 setores segundo a classificação de manual (GICS): Tecnologia, Financeiro, Saúde, Energia, Consumo, Industrial, Automotivo e Telecom. A partir dos retornos diários dessas ações, o pipeline aplica duas técnicas clássicas de aprendizado de máquina não supervisionado — **PCA** (redução de dimensionalidade) e **K-Means** (agrupamento) — para responder a uma pergunta específica:

PERGUNTA CENTRAL


A classificação setorial "de manual" ainda explica como essas ações se movem no dia a dia, ou o mercado agrupa as empresas por outra lógica — sensibilidade a juros, exposição a commodities, exposição ao ciclo de investimento em IA, risco geopolítico?

PCA e K-Means são adequados a essa pergunta porque nenhum dos dois algoritmos recebe o rótulo "Setor" como entrada — eles enxergam apenas séries numéricas de retorno. Se os grupos encontrados pelo K-Means coincidirem com a coluna de setor, isso é evidência de que a classificação de manual continua sendo a força dominante. Se os grupos cruzarem setores oficiais, há uma força macroeconômica mais forte unindo essas empresas do que a atividade declarada de cada uma.

2 Dados e pipeline de processamento

Os preços são obtidos via `yfinance` (`period="1y"`, `auto_adjust=False`, coluna `Adj Close`), cobrindo cerca de 252 pregões. Ações com histórico incompleto no período são descartadas (`dropna(axis=1, how="any")`) para garantir uma matriz retangular sem buracos. Em seguida, os preços são convertidos em **retornos percentuais diários** (`pct_change()`), a unidade correta para comparar ações de preços absolutos muito diferentes.

Figura 1 — Pipeline de processamento (app.py)



Cada seta é uma transformação aplicada sobre a matriz de dados; o resultado final alimenta os gráficos do Streamlit.

Um detalhe de implementação central para tudo o que segue: a matriz de retornos é **transposta** (`company_returns = returns.T`) antes da padronização e do PCA. Isso inverte o papel usual de linhas e colunas: cada **empresa** vira uma amostra (linha) e cada **dia de negociação** vira uma variável/feature (coluna). Em outras palavras, o PCA aqui não procura "os dias mais importantes do ano" — ele procura **os eixos ao longo dos quais as 40 empresas mais diferem entre si**, tratando toda a trajetória de 252 dias de cada ação como sua "impressão digital".

3 PCA — implementação e o que cada componente mede

3.1 Padronização e ajuste do modelo

Antes do PCA, os dados passam por `StandardScaler().fit_transform(company_returns)`. Como a matriz de entrada tem empresas nas linhas e dias nas colunas, o `StandardScaler` — que sempre padroniza *por coluna* — está recalculando, **para cada dia individual, a média e o desvio-padrão dos retornos das 40 empresas naquele dia**, e expressando o retorno de cada empresa como um z-score em relação às outras 39 no mesmo pregão.

NOTA TÉCNICA

Essa padronização por dia tem uma consequência interpretativa importante: como a média do mercado naquele dia já é subtraída antes do PCA rodar, o primeiro componente não é literalmente "o índice subiu ou desceu" — ele é o eixo que melhor separa as empresas **mais sensíveis** do mercado (beta alto) das **menos sensíveis** (beta baixo), porque uma ação de beta alto se desvia da média do dia em uma direção consistente ao longo do ano, enquanto uma ação de beta baixo quase não se desvia. Ou seja, PC1 continua sendo, na prática, um **fator de beta relativo ao mercado** — apenas medido como dispersão em torno da média diária, e não como o nível do índice em si.

O PCA é ajustado com `PCA(n_components=max_components, random_state=42)`, onde `max_components = min(10, nº empresas - 1, nº dias)` — no universo de 40 ações e ~251 dias, isso resulta em 10 componentes calculados de uma só vez. O usuário escolhe, via barra lateral, quantos desses componentes (de 2 a 10) alimentam o K-Means; o PCA em si é recalculado apenas quando os dados mudam, não a cada ajuste do slider.

3.2 Interpretação econômica de cada componente


Cada componente principal pode ser lido como um **fator de risco latente** — um padrão de comovimento que nenhuma variável do dataset original nomeia diretamente, mas que corresponde a temas macroeconômicos reconhecíveis quando se olha para quais tickers têm peso alto em cada eixo.

COMPONENTE	VARIÂNCIA TÍPICAMENTE EXPLICADA	LEITURA ECONÔMICA
PC1	~30–45%	Fator de mercado / beta. Separa ações de alta sensibilidade ao mercado geral (tecnologia, cíclicas) das de baixa sensibilidade (defensivas). É a evidência mais direta de que diversificar apenas entre setores não elimina o risco sistemático.
PC2	~10–20%	Eixo "crescimento/IA" vs. "defensivo/valor". De um lado, nomes ligados ao ciclo de investimento em infraestrutura de IA (NVDA, AMD, MSFT, GOOGL, META); do outro, pagadoras de dividendo estável e mais sensíveis a juros (KO, PEP, PG, JNJ, VZ).
PC3	~5–12%	Fator commodity/energia. Isola XOM, CVX, COP, SLB como bloco quase independente do resto do mercado, reagindo a choques geopolíticos de oferta de petróleo/gás em vez de sentimento geral de bolsa.
PC4 / PC5	~3–6% cada	Fatores mais sutis e específicos de subgrupo (ex.: sensibilidade de bancos a juros, exposição a tarifas de importação). É onde o "cotovelo" do gráfico de variância costuma aparecer.
PC6 em diante	poucos % cada	Ruído idiossincrático — eventos de uma única empresa (crise de produção da Boeing, resultado trimestral surpreendente), não mais um fator de mercado amplo.

3.3 Gráfico de variância explicada (scree plot)

O painel exibe, para cada um dos até 10 componentes calculados, a fração da variância total dos retornos que ele explica (`pca.explained_variance_ratio_`) e a soma acumulada até o número de componentes selecionado. A figura abaixo é um esquema ilustrativo do formato típico dessa curva — os valores reais mudam a cada execução, porque os dados são baixados ao vivo.

Figura 2 — Formato esquemático do scree plot



Esquemático baseado nos padrões descritos em CONCLUSOES.md — não são valores medidos de uma execução real. O "cotovelo" (queda acentuada seguida de cauda achatada) costuma aparecer entre PC3 e PC5.

3.4 O trade-off do número de componentes

Nº DE PCS	O QUE CAPTURA	CONSEQUÊNCIA PARA OS CLUSTERS
2	Só mercado geral (PC1) + crescimento vs. defensivo (PC2); ~40–55% da variância.	Separação simples de visualizar, mas energia e industriais tendem a ficar mal classificados.
3–5 (padrão do app)	Mercado + growth/value + energia + 1–2 fatores sutis; ~65–80% da variância.	Clusters interpretáveis e alinhados à intuição econômica, cruzando o setor oficial em pontos pontuais e explicáveis.
8–10	Reconstrói >85–90% da variância original, mas os componentes extras já são majoritariamente ruído de empresa.	Clusters mais fragmentados; o silhouette score tende a cair, pois o K-Means passa a reagir a ruído idiossincrático.

Esse é o trade-off clássico de viés-variância aplicado à redução de dimensionalidade: poucos componentes dão uma visão grosseira porém estável; muitos componentes dão uma visão detalhada porém ruidosa.

4 K-Means — implementação e o que cada agrupamento revela

4.1 Do espaço de PCA ao espaço de clusters

O K-Means não roda sobre os retornos brutos, e sim sobre `cluster_features`: as n primeiras colunas dos escores de PCA (`pca_scores_full[:, :n_components]`), onde n é o número escolhido na barra lateral. Isso é intencional — clusterizar diretamente sobre ~251 dimensões de retorno diário seria dominado por ruído; clusterizar sobre um punhado de componentes principais concentra o algoritmo nos padrões de comovimento mais fortes já identificados pelo PCA. O ajuste usa `KMeans(n_clusters=k, random_state=42, n_init=10)`: dez inicializações aleatórias diferentes, mantendo a de menor inércia, com semente fixa para reprodutibilidade dentro da mesma sessão de dados.

4.2 Escolha de k e o silhouette score

Para orientar a escolha do número de clusters, o app calcula o `silhouette_score` para todo k entre 2 e 10, usando os mesmos `cluster_features` que alimentam o K-Means principal. O silhouette mede, em uma escala de -1 a 1 , o quão bem cada ponto se encaixa no seu próprio cluster em relação aos clusters vizinhos — quanto maior, mais coesos e mais separados estão os grupos.

CUIDADO METODOLÓGICO


O silhouette nunca deve ser o único critério de escolha. Um k com score ligeiramente menor, mas que produz clusters interpretáveis e alinhados a eventos reais de mercado, é mais útil para uma análise de negócio do que o k "matematicamente ótimo" que fragmenta o resultado em grupos sem sentido econômico (tipicamente clusters de 1–2 ações isoladas por um evento pontual).

4.3 Interpretação econômica por número de clusters

K	O QUE EMERGE
2	<i>Risk-on vs. risk-off</i> . A divisão mais grosseira possível: ações de alta volatilidade/beta (tecnologia, TSLA) de um lado, ações de baixa volatilidade (consumo básico, saúde, telecom) do outro — a dicotomia clássica de mercado, redescoberta sem qualquer rótulo de setor.
3–4 (padrão do app)	Ponto de equilíbrio ("sweet spot") onde o silhouette costuma ser mais alto e os clusters ainda contam uma história simples: tipicamente um grupo "IA/crescimento" (NVDA, AMD, MSFT, GOOGL, META, ORCL, CRM, ADBE), um grupo "energia/commodities" (XOM, CVX, COP, SLB), um grupo "defensivas/dividendo" (KO, PEP, PG, WMT, JNJ, VZ, T) e um grupo "financeiro/cíclico" (JPM, BAC, GS, MS, WFC, AXP, C + industriais como CAT, HON, GE).
5–6	Subestruturas dentro de setores "artificiais" começam a aparecer — por exemplo, separação entre hardware/semicondutores (NVDA, AMD, INTC) e software/nuvem (MSFT, ORCL, CRM, ADBE), ou entre bancos de investimento (GS, MS) e bancos comerciais tradicionais (WFC, JPM, BAC, C).
≥ 7	Superfragmentação: clusters de 1–2 ações isoladas por eventos idiossincráticos (ex.: Boeing sozinha por causa de sua crise de produção). O silhouette tende a cair — sinal de que o algoritmo parou de encontrar fatores de mercado e passou a isolar ruído.

4.4 Projeção 2D dos clusters

Como só é possível desenhar dois eixos por vez, o app deixa o usuário escolher quais dois componentes visualizar em um gráfico de dispersão — mas os clusters são sempre calculados usando todos os n componentes selecionados, de modo que o gráfico 2D é uma "sombra" parcial da separação real em maior dimensão. O esquema abaixo ilustra a lógica para $k=4$ usando PC1 (fator de mercado/beta) no eixo X e PC2 (crescimento vs. defensivo) no eixo Y.



5 Limites metodológicos e leitura crítica

- **PCA e K-Means não sabem o que é uma empresa.** Eles só veem números. Quando os clusters batem com a intuição econômica (energia junta, IA junta), isso é evidência de que o mercado precifica essas empresas por fatores de risco comuns — não é um artefato do algoritmo.
- **A classificação setorial GICS é uma simplificação.** O comportamento real de preço frequentemente obedece a fatores macroeconômicos (juros, geopolítica, ciclo de IA) que atravessam múltiplos setores oficiais.
- **Os resultados são regime-dependentes.** Como o app sempre baixa "1 ano" a partir da data de execução, rodar o mesmo código em datas diferentes pode produzir clusters diferentes — isso não é um bug, é evidência de que as correlações de mercado mudam conforme o contexto macro do momento.
- **Correlação não é causalidade.** O modelo mostra *que* empresas se movem juntas; a explicação de *por que* vem da leitura do contexto macro feita por quem interpreta os resultados, não do algoritmo em si.

6 Conclusão

O pipeline implementado em `app.py` demonstra, de forma reproduzível e interativa, como duas técnicas de aprendizado não supervisionado — PCA e K-Means — podem extrair estrutura econômica de dados de mercado sem qualquer rótulo de setor. O PCA comprime ~251 dimensões diárias de retorno em um punhado de fatores de risco interpretáveis (mercado/beta, crescimento vs. valor, energia, ruído idiossincrático); o K-Means, operando sobre esses fatores, reconstrói agrupamentos que ora confirmam a classificação setorial de manual, ora a contradizem de maneiras economicamente explicáveis — como uma Tesla precificada mais como aposta em IA/robótica do que como montadora tradicional. O resultado central do trabalho não é um número fixo, mas um método: uma forma sistemática de perguntar aos próprios dados de preço "quem se parece com quem", e de comparar a resposta com o que a classificação oficial já pressupõe.

7 Referências

- Pedregosa, F. et al. *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 2011 — implementações de `PCA`, `KMeans`, `StandardScaler` e `silhouette_score` utilizadas no projeto.
- Yahoo Finance, via biblioteca `yfinance` — fonte dos preços diários ajustados das 40 ações do universo analisado.
- Jolliffe, I. T. *Principal Component Analysis*. Springer, 2002 — fundamentação matemática da técnica de redução de dimensionalidade.
- `app.py` e `CONCLUSOES.md` — código-fonte e roteiro de interpretação que fundamentam este relatório (repositório do trabalho).